ATELIER 3 – CI/CD POUR LE MACHINE LEARNINGGITHUB ACTIONS + CML

MANAL FADIL

Année : 2025-2026

1. Objectif de l'atelier

L’objectif de cet atelier est de mettre en place une première brique MLOps consistant à automatiser l’entraînement d’un modèle de Machine Learning à chaque git push, puis de publier automatiquement les métriques de performance et la matrice de confusion directement sur GitHub grâce à GitHub Actions et CML.

2. Description du projet

Le projet repose sur un cas de prédiction du churn client à partir d’un dataset tabulaire.

Le dépôt GitHub contient :

dataset.csv : jeu de données,

script.py : script d’entraînement et d’évaluation du modèle,

requirements.txt : dépendances Python,

.github/workflows/cml-churn.yaml : pipeline CI/CD.

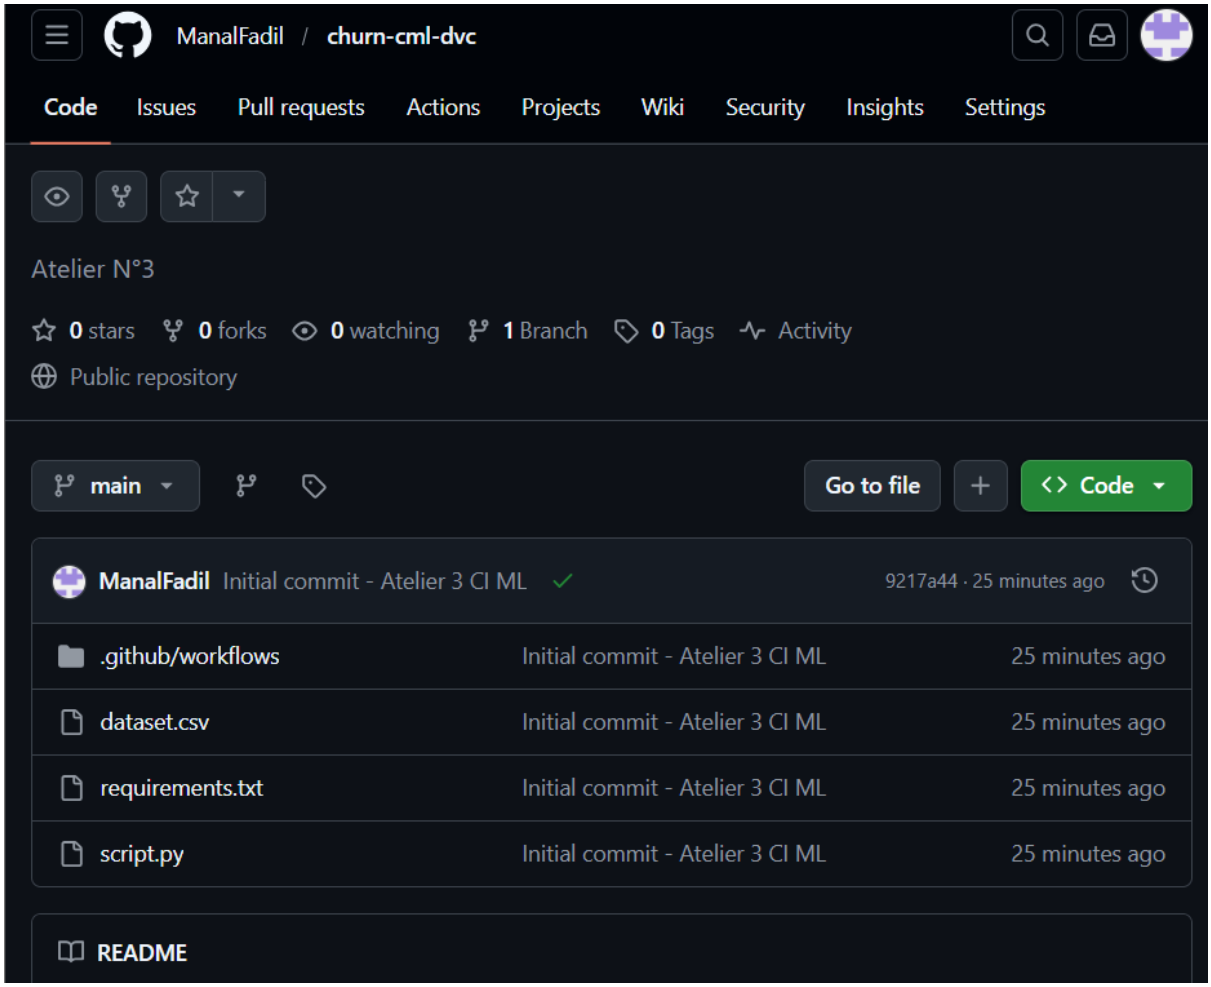

3. Pipeline MLOps mis en place

À chaque push sur le dépôt GitHub :

a. GitHub Actions démarre une machine virtuelle Ubuntu.
b. L'environnement Python est installé.
c. Les dépendances sont installées via requirements.txt.
d. Le script script.py est exécuté automatiquement.
e. Les fichiers metrics.txt et conf_matrix.png sont générés.
f. CML publie un commentaire automatique sur GitHub contenant les métriques et la matrice de confusion.

4. Modèle et métriques

Le modèle utilisé est un **RandomForestClassifier**.

Trois stratégies sont testées :

- sans gestion du déséquilibre,
- avec pondération des classes,
- avec sur-échantillonnage (SMOTE).

5. Résultat obtenu

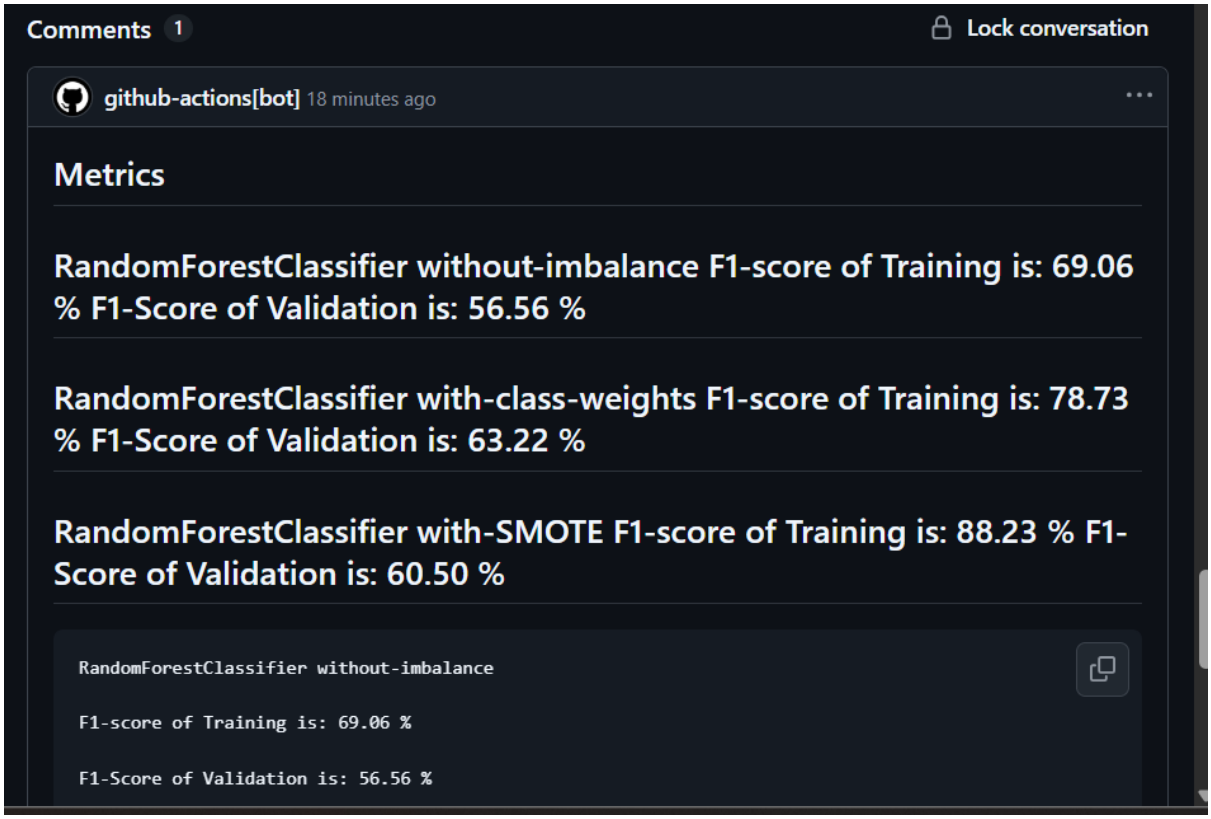

RandomForestClassifier with-SMOTE F1-score of Training is: 88.23 % F1-Score of Validation is: 60.50 %

```
RandomForestClassifier without-imbalance

F1-score of Training is: 69.06 %

F1-Score of Validation is: 56.56 %


RandomForestClassifier with-class-weights

F1-score of Training is: 78.73 %

F1-Score of Validation is: 63.22 %


RandomForestClassifier with-SMOTE

F1-score of Training is: 88.23 %

F1-Score of Validation is: 60.50 %
```
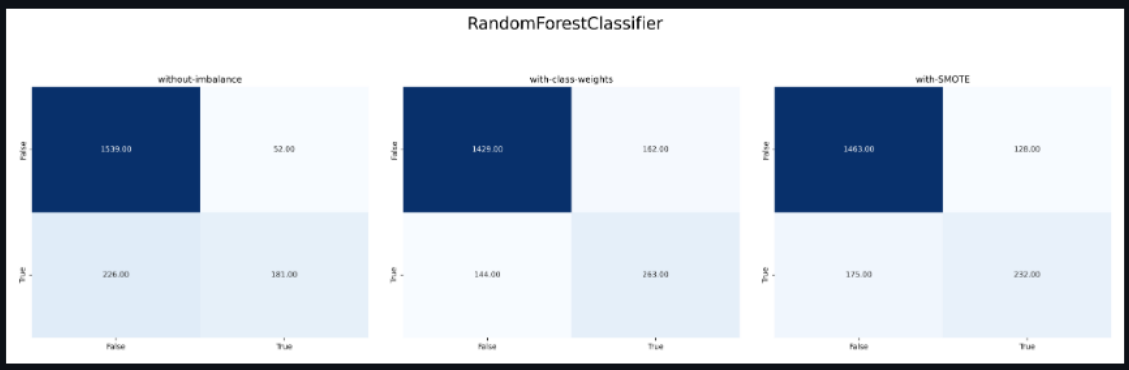
Confusion Matrix